



PYTHON

PCAD – CERTIFIED ASSOCIATE DATA ANALYST WITH PYTHON
CHAPTER 1 – DATA ACQUISITION AND PRE-PROCESSING

1

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

Data Collection, Integration, and Storage

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Explica y compara los métodos de recopilación de datos y su uso en la investigación, los negocios y la analítica.
- A. Explorar diferentes técnicas: Encuestas, entrevistas, web scraping (extracción de datos web).
 - **Encuestas:** Método de recolección de datos basado en cuestionarios estructurados aplicados a una muestra de personas. Permiten obtener información estandarizada y cuantificable sobre opiniones, comportamientos o características de una población.
 - **Entrevistas:** Técnica cualitativa en la que se recoge información mediante una conversación guiada entre entrevistador y participante. Puede ser estructurada, semiestructurada o abierta, y permite profundizar en experiencias, motivaciones y percepciones.
 - **Web scraping:** Proceso automatizado de extracción de datos desde sitios web mediante scripts o herramientas. Permite recopilar grandes volúmenes de información pública, pero debe realizarse respetando aspectos legales, éticos y las políticas de uso de los sitios web.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Explica y compara los métodos de recopilación de datos y su uso en la investigación, los negocios y la analítica.
- B. Analizar el muestreo representativo, los desafíos en la recopilación de datos y las diferencias entre la investigación cualitativa y cuantitativa.
 - **Muestreo representativo:** Consiste en seleccionar una muestra que refleje fielmente las características de la población total. Se busca evitar sesgos mediante técnicas como el muestreo aleatorio o estratificado, garantizando que los resultados del análisis puedan generalizarse.
 - **Desafíos en la recopilación de datos:** Incluyen problemas de calidad (datos incompletos o incorrectos), sesgos en la recolección, limitaciones de acceso a fuentes fiables, costos elevados y cuestiones legales o éticas relacionadas con la privacidad y el uso de la información.
 - **Investigación cualitativa vs cuantitativa:** La investigación cualitativa se centra en comprender fenómenos en profundidad mediante datos no numéricos (entrevistas, opiniones, observaciones). La cuantitativa analiza datos numéricos para identificar patrones, relaciones y tendencias, permitiendo mediciones objetivas y generalizables.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Explica y compara los métodos de recopilación de datos y su uso en la investigación, los negocios y la analítica.
- C. Examinar las consideraciones legales y éticas en la recopilación de datos.
 - La recopilación de datos debe cumplir con leyes de protección de privacidad como el Reglamento General de Protección de Datos (RGPD), que exige recoger solo los datos necesarios, con una finalidad clara y con base legal (como el consentimiento).
 - Además, obliga a informar con transparencia y garantizar derechos como acceso o eliminación.
 - Desde el punto de vista ético, implica respetar la privacidad, evitar sesgos y no usar los datos para fines distintos o perjudiciales. Una gestión responsable genera confianza y reduce riesgos para las personas.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Explica y compara los métodos de recopilación de datos y su uso en la investigación, los negocios y la analítica.
- D. Explicar la importancia de la anonimización de datos para mantener la privacidad y la confidencialidad, particularmente con la información de identificación personal (PII).
 - La privacidad y la confidencialidad implican proteger la información personal y garantizar que solo personas autorizadas accedan a ella. La **Personal Identifiable Information** (PII) incluye datos como nombre, dirección o DNI, que pueden identificar a un individuo y requieren especial cuidado en su manejo y almacenamiento.
 - La **anonimización** de datos consiste en eliminar o transformar esos identificadores para que no sea posible asociar la información a una persona concreta. Esto permite usar los datos con fines de análisis o investigación reduciendo riesgos, siempre asegurando que la reidentificación no sea posible.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Explica y compara los métodos de recopilación de datos y su uso en la investigación, los negocios y la analítica.
- E. Investigar el impacto de la recopilación de datos en la formación de estrategias empresariales, la precisión de la investigación de mercado, la evaluación de riesgos, la formulación de políticas y las decisiones comerciales.
 - La recopilación de datos es un pilar fundamental para la toma de decisiones en entornos empresariales y públicos, ya que influye directamente en la calidad de los análisis y en la capacidad de anticiparse a cambios.
 - En la **formación de estrategias empresariales**, los datos permiten identificar tendencias del mercado, segmentar clientes y detectar oportunidades de crecimiento. Una recolección de datos precisa y bien estructurada mejora la capacidad de diseñar estrategias competitivas y adaptativas.
 - En la **investigación de mercado**, la calidad de los datos determina la precisión de los resultados. Datos sesgados o incompletos pueden llevar a interpretaciones erróneas sobre las preferencias del consumidor, mientras que datos fiables permiten comprender mejor la demanda y ajustar productos o servicios.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Explica y compara los métodos de recopilación de datos y su uso en la investigación, los negocios y la analítica.
- E. Investigar el impacto de la recopilación de datos en la formación de estrategias empresariales, la precisión de la investigación de mercado, la evaluación de riesgos, la formulación de políticas y las decisiones comerciales.
 - En la **evaluación de riesgos**, los datos históricos y en tiempo real ayudan a predecir posibles problemas financieros, operativos o de mercado. Esto permite a las organizaciones anticiparse a escenarios adversos y tomar medidas preventivas más efectivas.
 - En la **formulación de políticas**, especialmente en el sector público, los datos respaldan decisiones basadas en evidencia. Una buena recopilación de datos mejora la asignación de recursos y la creación de políticas más eficaces y justas.
 - En la **toma de decisiones empresariales**, los datos reducen la incertidumbre y permiten decisiones más informadas. Sin embargo, la mala calidad de los datos puede conducir a estrategias ineficientes o decisiones equivocadas con impacto económico significativo.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Explica y compara los métodos de recopilación de datos y su uso en la investigación, los negocios y la analítica.
- F. Explicar el proceso y las metodologías de la recopilación de datos, incluyendo el diseño de encuestas, la selección de la audiencia y las entrevistas estructuradas.
 - El proceso de **recopilación de datos** comienza definiendo el objetivo del estudio: qué información se necesita y para qué se va a utilizar. A partir de ahí se elige la metodología más adecuada, que puede ser cuantitativa, cualitativa o mixta, según el tipo de análisis requerido. Esta planificación inicial es clave para garantizar que los datos recogidos sean relevantes y útiles.
 - El **diseño de encuestas** consiste en crear cuestionarios claros, estructurados y sin ambigüedades. Incluye la selección del tipo de preguntas (cerradas, abiertas, escalas), el orden lógico de los ítems y la validación previa para evitar sesgos o errores de interpretación. Un buen diseño mejora la calidad y comparabilidad de las respuestas.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Explica y compara los métodos de recopilación de datos y su uso en la investigación, los negocios y la analítica.
- F. Explicar el proceso y las metodologías de la recopilación de datos, incluyendo el diseño de encuestas, la selección de la audiencia y las entrevistas estructuradas.
 - La **selección de la audiencia** (muestreo) implica elegir a los participantes que representarán a la población objetivo. Puede realizarse mediante técnicas como muestreo aleatorio, estratificado o por conveniencia. Una selección adecuada asegura que los resultados sean representativos y generalizables.
 - Las **entrevistas estructuradas** son una técnica en la que se sigue un guion fijo de preguntas, aplicado de la misma forma a todos los participantes. Esto permite obtener datos consistentes y comparables, reduciendo la variabilidad del entrevistador y facilitando el análisis posterior.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Agrupar datos de múltiples fuentes e integrarlos en conjuntos de datos (datasets).
- A. Explicar las técnicas para combinar datos de diversas fuentes, como bases de datos, APIs y almacenamiento basado en archivos.
 - **Técnicas para combinar datos de distintas fuentes:** La integración de datos desde bases de datos, APIs y archivos se realiza mediante procesos de **ETL (Extract, Transform, Load)**, donde los datos se extraen de diferentes orígenes, se transforman a un formato común y se cargan en un sistema unificado. También se utilizan herramientas de integración de datos, conectores de APIs para datos en tiempo real, y consultas SQL para unir bases de datos mediante joins. En entornos modernos, los **data lakes** y **data warehouses** permiten centralizar datos estructurados y no estructurados para su análisis.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Agrupar datos de múltiples fuentes e integrarlos en conjuntos de datos (datasets).
- B. Abordar los desafíos en la agregación de datos, incluyendo las disparidades en los formatos de datos y los problemas de alineación.
 - **Desafíos en la agregación de datos:** Uno de los principales problemas es la disparidad de formatos, ya que los datos pueden venir en JSON (APIs), CSV (archivos) o estructuras relacionales (bases de datos). También surgen problemas de alineación, como diferencias en nombres de variables, unidades de medida o identificadores inconsistentes entre fuentes. Además, puede haber datos duplicados o faltantes, lo que complica la integración y requiere procesos de limpieza y normalización.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Agrupar datos de múltiples fuentes e integrarlos en conjuntos de datos (datasets).
- C. Comprender la importancia de la consistencia y precisión de los datos en los conjuntos de datos agregados.
 - **Importancia de la consistencia y precisión:** La consistencia garantiza que los datos combinados mantengan reglas uniformes (mismos formatos, definiciones y estructuras), mientras que la precisión asegura que los valores reflejen correctamente la realidad. Sin estos dos elementos, los análisis pueden producir resultados erróneos, sesgados o contradictorios, afectando la toma de decisiones. Por ello, la validación y estandarización son esenciales en cualquier dataset agregado.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- **Explicar diversas soluciones de almacenamiento de datos.**
- A. Comprender varios métodos de almacenamiento de datos y sus aplicaciones adecuadas.
 - Los datos pueden almacenarse en bases de datos relacionales (SQL) para información estructurada y transaccional, bases NoSQL para datos flexibles o no estructurados, sistemas de archivos (CSV, Excel) para usos simples o locales, y plataformas analíticas como data warehouses o data lakes para grandes volúmenes de datos.
 - La elección depende del volumen, la velocidad de acceso y el tipo de análisis requerido.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Explicar diversas soluciones de almacenamiento de datos.
- B. Distinguir entre los conceptos de almacenes de datos (data warehouses), lagos de datos (data lakes) y opciones de almacenamiento basadas en archivos como CSV y Excel.
 - Un **data lake** es un repositorio donde se almacenan grandes volúmenes de datos en su formato original, ya sean estructurados, semiestructurados o no estructurados (como texto, imágenes o logs). No requiere una estructura previa, lo que permite máxima flexibilidad para análisis futuros, especialmente en big data y machine learning. **Prioriza la flexibilidad y el almacenamiento bruto.**
 - Un **data warehouse** es un sistema de almacenamiento de datos estructurados y organizados previamente para su análisis. Los datos se limpian, transforman e integran antes de almacenarse, lo que facilita consultas rápidas y la generación de informes para la toma de decisiones empresariales. **Prioriza la estructura, la calidad y la optimización para análisis.**
 - Formatos como **CSV y Excel** son soluciones de archivo simples, útiles para pequeños conjuntos de datos, pero limitadas en escalabilidad, seguridad y rendimiento.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- **Explicar diversas soluciones de almacenamiento de datos.**
- C. Explicar los conceptos de las soluciones de almacenamiento en la nube y su creciente papel en la gestión de datos.
 - El almacenamiento en la nube permite guardar y gestionar datos en servidores remotos accesibles por internet. Soluciones como Amazon S3 o Google Cloud Storage ofrecen escalabilidad, seguridad, acceso global y reducción de infraestructura local.
 - Su uso ha crecido porque facilita el manejo de grandes volúmenes de datos, la integración con herramientas analíticas y el trabajo colaborativo en tiempo real.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

Data Cleaning and Standardization

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- El **data cleaning** consiste en detectar y corregir errores en los datos: valores faltantes, duplicados, inconsistencias o registros incorrectos. Este paso es clave para asegurar que el análisis sea fiable y evitar conclusiones erróneas.
- La **estandarización** implica transformar los datos a formatos coherentes (fechas, unidades, categorías, nombres), de modo que sean comparables y fáciles de procesar. Juntos, estos procesos mejoran la calidad, consistencia y utilidad de los datos para el análisis.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender los datos estructurados y no estructurados y sus implicaciones en el análisis de datos
- A. Reconocer las características de los **datos estructurados**, como las bases de datos y las hojas de cálculo, y su uso directo en el análisis.
 - Los datos estructurados son aquellos que están organizados de manera clara y ordenada, normalmente en filas y columnas. Este tipo de datos sigue un formato definido, lo que facilita su almacenamiento, búsqueda y análisis.
 - Características principales
 - Organización fija: Los datos siguen una estructura específica.
 - Fácil acceso: Se pueden localizar rápidamente mediante consultas.
 - Compatibilidad con bases de datos: Se almacenan comúnmente en bases de datos relacionales y hojas de cálculo.
 - Consistencia: Todos los registros mantienen el mismo formato.
 - Ejemplos
 - Bases de datos empresariales, hojas de cálculo de Excel, registros financieros, Inventarios de productos o información de clientes.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender los datos estructurados y no estructurados y sus implicaciones en el análisis de datos
- A. Reconocer las características de los **datos estructurados**, como las bases de datos y las hojas de cálculo, y su uso directo en el análisis.
 - Ventajas en el análisis
 - Los datos estructurados permiten realizar análisis de forma rápida y eficiente porque:
 - Son fáciles de clasificar y filtrar.
 - Pueden analizarse con herramientas tradicionales como SQL, Excel o software estadístico.
 - Facilitan la generación de gráficos, reportes y métricas.
 - Aplicaciones comunes
 - Análisis financiero.
 - Gestión empresarial.
 - Control de inventarios.
 - Sistemas bancarios.
 - Estadísticas y reportes.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender los datos estructurados y no estructurados y sus implicaciones en el análisis de datos
- B. Comprender los datos **no estructurados**, incluidos textos, imágenes y videos, y el procesamiento adicional que requieren para su análisis.
 - Los datos no estructurados son aquellos que no siguen un formato fijo ni organizado. Representan una gran parte de la información generada actualmente y requieren procesos adicionales para poder analizarlos.
 - Características principales
 - Formato variable: No poseen una estructura uniforme.
 - Gran volumen: Se generan constantemente en redes sociales, multimedia y plataformas digitales.
 - Mayor complejidad: Son más difíciles de almacenar y procesar.
 - Ejemplos: textos y documentos, correos electrónicos, imágenes, vídeos y audios o publicaciones en redes sociales.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender los datos estructurados y no estructurados y sus implicaciones en el análisis de datos
- B. Comprender los datos **no estructurados**, incluidos textos, imágenes y videos, y el procesamiento adicional que requieren para su análisis.
 - Para analizar datos no estructurados se necesitan tecnologías avanzadas como:
 - Procesamiento de lenguaje natural (NLP): Para interpretar textos.
 - Visión artificial: Para analizar imágenes y videos.
 - Machine Learning e Inteligencia Artificial: Para identificar patrones y extraer información útil.
 - Desafíos principales
 - Dificultad para clasificar la información.
 - Mayor necesidad de almacenamiento.
 - Procesamiento más lento y costoso.
 - Complejidad en la extracción de datos relevantes.
 - A pesar de sus desafíos, los datos no estructurados son muy valiosos porque contienen información detallada sobre comportamientos, opiniones y tendencias.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender los datos estructurados y no estructurados y sus implicaciones en el análisis de datos.
- C. Explorar cómo la estructura de los datos afecta su **almacenamiento**, recuperación y los métodos analíticos empleados.
 - Datos estructurados
 - Se almacenan en bases de datos relacionales.
 - Requieren menos complejidad organizativa.
 - Facilitan la administración y seguridad de la información.
 - Datos no estructurados
 - Necesitan sistemas más flexibles como almacenamiento en la nube o bases NoSQL.
 - Ocupan más espacio.
 - Requieren tecnologías especializadas para gestionarlos.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender los datos estructurados y no estructurados y sus implicaciones en el análisis de datos.
- C. Explorar cómo la estructura de los datos afecta su almacenamiento, **recuperación** y los métodos analíticos empleados.
 - Datos estructurados
 - La búsqueda es rápida y precisa.
 - Se utilizan consultas simples mediante SQL.
 - Los resultados son fáciles de interpretar.
 - Datos no estructurados
 - La recuperación es más compleja.
 - Se necesitan algoritmos de búsqueda avanzada e inteligencia artificial.
 - El proceso puede ser más lento debido al volumen y variedad de información.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender los datos estructurados y no estructurados y sus implicaciones en el análisis de datos.
- C. Explorar cómo la estructura de los datos afecta su almacenamiento, recuperación y los **métodos analíticos** empleados.
 - Datos estructurados
 - Permiten análisis estadísticos tradicionales.
 - Son ideales para dashboards y reportes.
 - Facilitan predicciones basadas en datos históricos.
 - Datos no estructurados
 - Requieren análisis avanzado y técnicas de IA.
 - Permiten descubrir patrones complejos y comportamientos humanos.
 - Son fundamentales en análisis de sentimientos, reconocimiento facial y sistemas de recomendación.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- A. Identificar errores e inconsistencias en los datos mediante diversos métodos de diagnóstico.
 - ¿Qué son los errores e inconsistencias? Son problemas en los datos que afectan su precisión, coherencia o utilidad para el análisis.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- A. Identificar errores e inconsistencias en los datos mediante diversos métodos de diagnóstico.
 - Métodos de diagnóstico más utilizados
 - **1. Validación de formatos**
 - Verificar tipos de datos correctos.
 - Ejemplo: Edad → número entero.
 - Fecha → formato DD/MM/AAAA.
 - **2. Estadística descriptiva**
 - Uso de media, mediana, desviación estándar y percentiles.
 - Permite detectar:
 - Valores extremos.
 - Distribuciones anómalas.
 - Inconsistencias numéricas.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- A. Identificar errores e inconsistencias en los datos mediante diversos métodos de diagnóstico.
 - Métodos de diagnóstico más utilizados
 - **3. Reglas de negocio**
 - Validaciones basadas en lógica del dominio.
 - Ejemplo:
 - Una edad negativa es inválida.
 - Un pedido no puede tener fecha de entrega anterior a la compra.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- A. Identificar errores e inconsistencias en los datos mediante diversos métodos de diagnóstico.
 - Métodos de diagnóstico más utilizados
 - **4. Visualización de datos**
 - Histogramas.
 - Boxplots.
 - Diagramas de dispersión.
 - Facilitan la detección de:
 - Outliers.
 - Duplicados.
 - Patrones sospechosos.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- A. Identificar errores e inconsistencias en los datos mediante diversos métodos de diagnóstico.
 - Métodos de diagnóstico más utilizados
 - **5. Comparación entre fuentes**
 - Cruce de datos entre sistemas.
 - Identificación de inconsistencias entre bases de datos.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- B. Abordar la información faltante, inexacta o engañosa.
 - **Impacto de los errores**
 - Decisiones incorrectas.
 - Modelos predictivos poco fiables.
 - Pérdida de confianza en los resultados.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- B. Abordar la información faltante, inexacta o engañosa.
 - **Información faltante** → Datos ausentes que dificultan el análisis.
 - Ejemplos:
 - Campos vacíos.
 - Registros incompletos.
 - Soluciones
 - Imputación de datos.
 - Eliminación de registros.
 - Recolección adicional.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- B. Abordar la información faltante, inexacta o engañosa.
 - **Información inexacta** → Datos incorrectos o erróneos.
 - Ejemplos
 - Edad = 250.
 - Precio negativo.
 - Soluciones
 - Corrección mediante validaciones.
 - Verificación con fuentes originales.
 - Uso de reglas automáticas.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- B. Abordar la información faltante, inexacta o engañosa.
 - **Información engañosa** → Datos técnicamente válidos pero que inducen interpretaciones erróneas.
 - Ejemplos
 - Datos desactualizados.
 - Variables mal etiquetadas.
 - Sesgos en la recopilación.
 - Soluciones
 - Documentación clara.
 - Auditorías periódicas.
 - Transparencia en la metodología.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- C. Abordar problemas específicos de calidad de los datos: problemas en datos numéricos, registros duplicados, entradas de datos inválidas y valores faltantes.
 - **Problemas específicos de calidad de datos** → Problemas en datos numéricos.
 - Tipos comunes
 - Valores fuera de rango.
 - Errores de escala.
 - Problemas de precisión.
 - Ejemplo
 - Temperatura registrada como 500°C.
 - Técnicas de solución
 - Normalización.
 - Validación estadística.
 - Detección de outliers.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- C. Abordar problemas específicos de calidad de los datos: problemas en datos numéricos, registros duplicados, entradas de datos inválidas y valores faltantes.
 - **Problemas específicos de calidad de datos** → Registros duplicados
 - Problemas que generan
 - Sobreestimación.
 - Sesgo estadístico.
 - Incremento artificial de frecuencias.
 - Métodos de detección
 - Comparación de identificadores.
 - Similitud de texto.
 - Algoritmos de deduplicación.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- C. Abordar problemas específicos de calidad de los datos: problemas en datos numéricos, registros duplicados, entradas de datos inválidas y valores faltantes.
 - **Problemas específicos de calidad de datos** → Entradas inválidas
 - Ejemplos
 - Letras en campos numéricos.
 - Categorías inexistentes.
 - Soluciones
 - Restricciones de validación.
 - Listas controladas.
 - Tipado estricto.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- C. Abordar problemas específicos de calidad de los datos: problemas en datos numéricos, registros duplicados, entradas de datos inválidas y valores faltantes.
 - **Problemas específicos de calidad de datos** → Valores faltantes
 - Problemas
 - Pérdida de información.
 - Sesgo analítico.
 - Reducción de precisión.
 - Opciones de tratamiento
 - Imputación.
 - Eliminación.
 - Modelos robustos.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- D. Explicar los diferentes tipos de datos faltantes (**MCAR**, **MAR**, **MNAR**) y sus implicaciones en el análisis de datos.
 - MCAR (Missing Completely At Random) → Los datos faltan completamente al azar.
 - Características
 - No dependen de ninguna variable.
 - Menor riesgo de sesgo.
 - Ejemplo
 - Fallo aleatorio del sistema.
 - Implicaciones
 - El análisis sigue siendo relativamente confiable.
 - Se pueden usar técnicas simples de imputación.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- D. Explicar los diferentes tipos de datos faltantes (MCAR, **MAR**, MNAR) y sus implicaciones en el análisis de datos.
 - MCAR (Missing At Random) → La ausencia depende de otras variables observadas.
 - Ejemplo
 - Personas jóvenes omiten ingresos con más frecuencia.
 - Implicaciones
 - Puede introducir sesgo.
 - Requiere técnicas estadísticas más avanzadas.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- D. Explicar los diferentes tipos de datos faltantes (MCAR, MAR, **MNAR**) y sus implicaciones en el análisis de datos.
 - MCAR (Missing Not At Random) → La ausencia depende del propio valor faltante.
 - Ejemplo
 - Personas con salarios altos no responden ingresos.
 - Implicaciones
 - Alto riesgo de sesgo.
 - Difícil de corregir.
 - Puede afectar gravemente los resultados.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- E. Explorar diversas técnicas para lidiar con datos faltantes, incluidos los métodos de imputación de datos.
 - **1. Eliminación de datos (Listwise deletion)** → Eliminar registros completos con valores faltantes.
 - Ventajas
 - Simplicidad.
 - Desventajas
 - Pérdida de información.
 - Posible sesgo.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- E. Explorar diversas técnicas para lidiar con datos faltantes, incluidos los métodos de imputación de datos.
 - **2. Imputación simple**
 - Media → Sustituir por el promedio.
 - Mediana → Útil cuando existen outliers.
 - Moda → Adecuada para datos categóricos.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- E. Explorar diversas técnicas para lidiar con datos faltantes, incluidos los métodos de imputación de datos.
 - **3. Imputación avanzada**
 - KNN Imputation (*K-Nearest Neighbors* o K-Vecinos más Cercanos) → Usa registros similares.
 - Regresión → Predice valores faltantes.
 - MICE (*Multivariate Imputation by Chained Equations* o Imputación Múltiple por Ecuaciones Encadenadas) → Genera múltiples imputaciones.
 - Machine Learning → Modelos predictivos avanzados.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- E. Explorar diversas técnicas para lidiar con datos faltantes, incluidos los métodos de imputación de datos.

Método	Ventaja	Desventaja
Eliminación	Fácil de implementar y rápido.	Pérdida de información valiosa y posible sesgo.
Media/Mediana/Moda	Rápido; mantiene el tamaño de la muestra.	Reduce la variabilidad y distorsiona las correlaciones.
KNN (K-Nearest Neighbors) (machine learning)	Más preciso; usa la similitud entre registros.	Alto coste computacional en bases de datos grandes.
MICE (Multivariable)	Muy robusto; ideal para datos complejos.	Complejo de configurar; requiere mayor tiempo de procesamiento.
Regresión	Preserva las relaciones estadísticas entre variables.	Puede sobreajustar los datos y subestimar el error.
Machine Learning (por ejemplo, Random Forest Imputation)	Captura patrones no lineales y relaciones complejas.	Actúa como "caja negra" y requiere un volumen alto de datos.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- F. Comprender las implicaciones de la corrección o eliminación de datos en la **integridad general** de los mismos y en los resultados del análisis.
 - Corrección excesiva
 - Puede distorsionar la realidad.
 - Introduce subjetividad.
 - Eliminación excesiva
 - Reduce tamaño muestral.
 - Disminuye representatividad.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- F. Comprender las implicaciones de la corrección o eliminación de datos en la integridad general de los mismos y en los **resultados del análisis**.
 - Posibles consecuencias
 - Sesgo estadístico.
 - Cambios en patrones.
 - Variación en resultados predictivos.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- F. Comprender las implicaciones de la corrección o eliminación de datos en la integridad general de los mismos y en los resultados del análisis.
 - Buenas prácticas
 - Documentar cambios.
 - Mantener trazabilidad.
 - Evaluar impacto antes de modificar datos.
 - Conservar copias originales.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- G. Explicar la importancia de la recopilación de datos en el contexto de la detección de valores atípicos (outliers).
 - Datos mal recolectados generan falsos outliers
 - Ejemplos:
 - Error humano.
 - Sensores defectuosos.
 - Problemas de medición.
 - Datos insuficientes dificultan la detección
 - Muestras pequeñas producen resultados poco fiables.
 - Se pierde contexto estadístico.
 - Beneficios de una buena recopilación
 - Mayor precisión.
 - Menor ruido.
 - Modelos más confiables.
 - Mejor interpretación.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Identificar, rectificar o eliminar datos erróneos.
- H. Explicar por qué los datos de alta calidad son cruciales para una detección precisa de valores atípicos.
 - Razones principales
 - 1. Precisión en la detección → Datos limpios permiten identificar anomalías reales.
 - 2. Reducción de falsos positivos → Errores de calidad pueden parecer outliers.
 - 3. Mejora del rendimiento de modelos → Muchos algoritmos son sensibles a valores atípicos.
 - 4. Mayor confianza analítica → Los resultados son más consistentes y reproducibles.
 - Consecuencias de mala calidad
 - Decisiones erróneas.
 - Modelos sesgados.
 - Interpretaciones incorrectas.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Data Cleaning and Standardization. Identify, rectify, or remove erroneous data.
- I. Explicar cómo los diferentes tipos de datos (numéricos, categóricos) pueden influir en las estrategias de detección de valores atípicos.
- 1. Datos numéricos
 - Técnicas comunes
 - **Z-score** (Puntuación estándar) → Es una medida estadística que describe la posición de un dato en relación con la media de un grupo de datos. Se mide en términos de desviaciones estándar..
 - **IQR** (Rango Intercuartílico) → Es un método basado en cuartiles para medir la dispersión estadística y detectar valores atípicos sin que la media los distorsione.
 - **DBSCAN** (*Density-Based Spatial Clustering of Applications with Noise*) → Es un algoritmo de machine learning no supervisado que agrupa puntos basándose en la densidad.
 - **Isolation Forest** → Es un algoritmo de machine learning diseñado específicamente para la detección de anomalías, basado en el concepto de "aislar" observaciones.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

■ Cálculo del z-score en Python con pandas

```
import pandas as pd

# Serie de datos
datos = [10, 12, 14, 15, 18, 10, 12, 14, 15, 18, 10, 12, 14, 15, 18, 100]

# Crear Series de pandas
s = pd.Series(datos)

# Calcular media y desviación estándar
media = s.mean()
std = s.std()

# Calcular z-score
z_scores = (s - media) / std

# Umbral para outliers
umbral = 2

# Detectar outliers
outliers = s[z_scores.abs() > umbral]

# Mostrar resultados
print("Z-scores:")
print(z_scores)

print("\nPosibles outliers:")
print(outliers.values)
```

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

■ Cálculo del z-score en Python con numpy

```
import numpy as np

# Serie de datos
datos = [10, 12, 14, 15, 18, 10, 12, 14, 15, 18, 10, 12, 14, 15, 18, 100]

# Convertir a array de NumPy
datos_np = np.array(datos)

# Calcular media y desviación estándar
media = np.mean(datos_np)
desviacion = np.std(datos_np)

# Calcular z-scores
z_scores = (datos_np - media) / desviacion

# Umbral típico para detectar outliers
umbral = 2

# Encontrar posibles outliers
outliers = datos_np[np.abs(z_scores) > umbral]

# Mostrar resultados
print("Media:", media)
print("Desviación estándar:", desviacion)
print("Z-scores:")
print(z_scores)

print("\nPosibles outliers:")
print(outliers)
```


CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

■ Cálculo del z-score en Python con scipy

```
import numpy as np
from scipy.stats import zscore

# Serie de datos
datos = [10, 12, 14, 15, 18, 10, 12, 14, 15, 18, 10, 12, 14, 15, 18, 100]

# Convertir a array de NumPy
datos_np = np.array(datos)

# Calcular z-scores con SciPy
z_scores = zscore(datos_np)

# Umbral típico para detectar outliers
umbral = 2

# Detectar posibles outliers
outliers = datos_np[np.abs(z_scores) > umbral]

# Mostrar resultados
print("Z-scores:")
print(z_scores)

print("\nPosibles outliers:")
print(outliers)
```

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Data Cleaning and Standardization. Identify, rectify, or remove erroneous data.
- I. Explicar cómo los diferentes tipos de datos (numéricos, categóricos) pueden influir en las estrategias de detección de valores atípicos.
 - 2. Datos categóricos
 - Dificultades
 - No existe distancia numérica directa.
 - Estrategias
 - Frecuencia de categorías.
 - Rareza estadística.
 - Reglas de asociación.
 - Ejemplo
 - Una categoría extremadamente rara puede indicar anomalía.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Data Cleaning and Standardization. Identify, rectify, or remove erroneous data.
- I. Explicar cómo los diferentes tipos de datos (numéricos, categóricos) pueden influir en las estrategias de detección de valores atípicos.
 - 3. Datos mixtos
 - Problema
 - Combinan variables numéricas y categóricas.
 - Soluciones
 - Codificación de variables.
 - Distancias mixtas.
 - Algoritmos híbridos.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender la normalización y el escalado de datos.
- A. Comprender la necesidad de la normalización de datos para llevar diferentes variables a una escala similar para el análisis comparativo.
 - La normalización de datos es fundamental cuando trabajamos con variables que tienen escalas diferentes (por ejemplo, edad en años y salario en miles de euros).
 - Sin normalización:
 - Las variables con valores grandes dominan los modelos.
 - Se distorsionan los resultados de algoritmos como regresión o clustering.
 - Con normalización:
 - Todas las variables se llevan a una escala comparable.
 - Se mejora la interpretación y el rendimiento de los modelos.
 - Se evita el sesgo por magnitud.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender la normalización y el escalado de datos.
- B. Comprender varios métodos de escalado, como el escalado Min-Max y la normalización Z-score.
 - **Min-Max**: Escala los valores de una variable a un rango fijo (normalmente entre 0 y 1). Se calcula restando el valor mínimo y dividiendo por el rango total, lo que mantiene la forma de la distribución, pero cambia la escala. El valor más bajo se convierte en 0, el más alto en 1, y los demás se distribuyen proporcionalmente en ese rango
 - **Z-score**: Transforma los datos para que tengan media 0 y desviación estándar 1. Cada valor indica cuántas desviaciones estándar se aleja de la media, útil para comparar variables con distintas escalas.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender la normalización y el escalado de datos.
- C. Explicar la codificación de variables categóricas para el análisis cuantitativo, incluidos los métodos de one-hot encoding (codificación estricta/uno-caliente) y label encoding (codificación por etiquetas).
 - **One-Hot Encoding**: Convierte una variable categórica en varias columnas binarias (0/1), una por cada categoría. Evita introducir un orden artificial entre categorías. (En pandas → `get_dummies`)
 - **Label Encoding**: Asigna un número entero a cada categoría (por ejemplo, “rojo”=0, “azul”=1). Es más compacto, pero puede introducir un orden que no siempre tiene sentido en los datos.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender la normalización y el escalado de datos.
- D. Explicar los pros y los contras de la **reducción de datos** (reducir el número de variables en consideración o simplificar los modelos frente a la pérdida de explicabilidad de los datos).
 - Ventajas:
 - Reduce la complejidad del modelo
 - Mejora la velocidad de entrenamiento
 - Evita overfitting
 - Simplifica la visualización
 - Desventajas:
 - Pérdida de información
 - Menor interpretabilidad
 - Riesgo de eliminar variables importantes

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender la normalización y el escalado de datos.
- E. Explicar los métodos para el manejo de valores atípicos (outliers), incluyendo técnicas de detección y tratamiento para asegurar la calidad de los datos.
 - Detección:
 - Z-score (valores $> |3|$)
 - IQR (rango intercuartílico)
 - Visualización (boxplots)
 - Tratamiento:
 - Eliminación
 - Capping (limitar valores extremos)
 - Transformaciones (log, sqrt)
 - Sustitución por media/mediana

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender la normalización y el escalado de datos.
- F. Comprender la importancia de la estandarización del formato de los datos en diferentes conjuntos de datos para mantener la consistencia, especialmente al tratar con formatos de fecha y hora (date-time) y valores numéricos.
 - Es clave para asegurar consistencia entre datasets.
 - Problemas comunes:
 - Fechas en distintos formatos (DD/MM/YYYY vs YYYY-MM-DD)
 - Decimales con coma o punto
 - Unidades diferentes (kg vs libras)
 - Mezcla de tipos de datos
 - Soluciones:
 - Normalizar formatos de fecha con librerías como pandas
 - Estandarizar unidades antes del análisis
 - Definir un esquema único de datos
 - Homogeneización de nombres y categorías. Se unifican etiquetas equivalentes (por ejemplo, “USA” y “Estados Unidos”) para evitar fragmentación de datos.
 - Conversión de tipos de datos. Se cambian formatos (texto a número, string a fecha) para asegurar que cada variable se use correctamente en el análisis.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Aplicar técnicas de limpieza y estandarización de datos.
- A. Realizar técnicas de imputación de datos, manipulación de cadenas de texto (strings), estandarización de formatos de datos, normalización booleana, normalización de mayúsculas/minúsculas y conversiones de texto a número.
 - Imputación de datos (missing values) → Consiste en rellenar valores nulos o faltantes:
 - Media / mediana (numéricos)
 - Moda (categóricos)
 - Valores constantes (ej. “desconocido”)
 - Métodos avanzados (KNN, regresión)
 - Manipulación de strings → Permite limpiar texto:
 - Eliminar espacios: " hola " → "hola"
 - Reemplazar caracteres
 - Extraer subcadenas

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Aplicar técnicas de limpieza y estandarización de datos.
- A. Realizar técnicas de imputación de datos, manipulación de cadenas de texto (strings), estandarización de formatos de datos, normalización booleana, normalización de mayúsculas/minúsculas y conversiones de texto a número.
 - Estandarización de formatos
 - Fechas: 12/05/2026 → 2026-05-12
 - Números: 1.000,5 → 1000.5
 - Normalización booleana → Convertir valores a formato consistente:
 - "yes", "true", "1" → True
 - "no", "false", "0" → False
 - Normalización de mayúsculas/minúsculas
 - "Madrid", "madrid", "MADRID" → "madrid"
 - Conversión string → número (Fundamental para análisis numérico y machine learning)
 - "100" → 100
 - "3.14" → 3.14

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Aplicar técnicas de limpieza y estandarización de datos.
- B. Analizar los pros y los contras de la imputación frente a la exclusión, y su impacto en la fiabilidad y validez del análisis.
 - **Imputación**
 - Ventajas:
 - Mantiene el tamaño del dataset
 - Reduce pérdida de información
 - Mejora estabilidad del modelo
 - Desventajas:
 - Puede introducir sesgo
 - Reduce variabilidad real
 - Depende de suposiciones

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Aplicar técnicas de limpieza y estandarización de datos.
- B. Analizar los pros y los contras de la imputación frente a la exclusión, y su impacto en la fiabilidad y validez del análisis.
 - **Exclusión** (eliminar datos)
 - Ventajas:
 - Evita introducir valores artificiales
 - Mantiene datos “puros”
 - Simple de implementar
 - Desventajas:
 - Pérdida de información
 - Puede reducir significativamente el dataset
 - Riesgo de sesgo si no es aleatorio

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Aplicar técnicas de limpieza y estandarización de datos.
- C. Explicar el concepto de **One-Hot Encoding** y su aplicación en la transformación de variables categóricas a un formato binario, preparando los datos para algoritmos de aprendizaje automático (machine learning).
 - Transforma variables categóricas en variables binarias.
 - Ejemplo:
 - Color: rojo; azul; verde
 - Se transforma en:

	rojo	azul	verde
■ 1	0	0	
■ 0	1	0	
■ 0	0	1	

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESING

- Aplicar técnicas de limpieza y estandarización de datos.
- C. Explicar el concepto de **One-Hot Encoding** y su aplicación en la transformación de variables categóricas a un formato binario, preparando los datos para algoritmos de aprendizaje automático (machine learning).
- **One-Hot Encoding.**
 - Ventajas:
 - Evita introducir orden artificial
 - Compatible con la mayoría de los algoritmos de machine learning
 - Desventajas:
 - Aumenta la dimensionalidad
 - Puede generar datasets muy grandes

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Aplicar técnicas de limpieza y estandarización de datos.
- D. Explicar el concepto de discretización (bucketization o binning) y su aplicación en la transformación de variables continuas en variables categóricas.
 - La bucketization convierte variables continuas en categorías.
 - Ejemplo:
 - Edad:0–18 → “joven”
 - 19–65 → “adulto”
 - 66+ → “senior”
 - Aplicaciones:
 - Simplificar modelos
 - Mejorar interpretabilidad
 - Crear segmentos de análisis

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESING

- Aplicar técnicas de limpieza y estandarización de datos.
- D. Explicar el concepto de discretización (bucketization o binning) y su aplicación en la transformación de variables continuas en variables categóricas.
 - Ventajas:
 - Reduce complejidad del modelo
 - Facilita interpretación
 - Útil para modelos basados en reglas
 - Desventajas:
 - Pérdida de información
 - Dependencia de cómo se definan los intervalos
 - Puede introducir arbitrariedad

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

Data Validation and Integrity

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Ejecutar y comprender métodos básicos de validación de datos
- A. Definir el concepto de "validación" (de tipo, de rango, de campos cruzados/cross-field) y asociarlos con herramientas (lógica de Python, verificaciones de esquema)
 - **Validación de datos:** Es el proceso de comprobar que los datos cumplen reglas predefinidas antes o durante su entrada y uso. Incluye verificar tipos de datos correctos, rangos válidos, formatos adecuados (por ejemplo, fechas o correos) y consistencia lógica entre campos. Su objetivo es prevenir errores desde el origen y garantizar que los datos sean utilizables para el análisis.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Ejecutar y comprender métodos básicos de validación de datos
- A. Definir el concepto de "validación" (de tipo, de rango, de campos cruzados/cross-field) y asociarlos con herramientas (lógica de Python, verificaciones de esquema)
- **Validación de datos.** Tipos de validación.
 - Type validation (tipo de dato)
 - Verifica que el dato sea del tipo correcto (int, float, string, date)
 - Ejemplo: edad debe ser un número entero
 - Range validation (rango)
 - Comprueba que los valores estén dentro de un intervalo válido
 - Ejemplo: edad entre 0 y 120
 - Cross-field validation (validación entre campos)
 - Compara múltiples campos entre sí
 - Ejemplo: fecha de inicio < fecha de fin

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Ejecutar y comprender métodos básicos de validación de datos
- A. Definir el concepto de "validación" (de tipo, de rango, de campos cruzados/cross-field) y asociarlos con herramientas (lógica de Python, verificaciones de esquema)
 - **Validación de datos.** Herramientas de validación.
 - Python (condiciones lógicas, if, assert)
 - Pandas (filtrado y validación de columnas)
 - Esquemas de datos (JSON Schema, Pydantic)
 - Bases de datos (constraints: NOT NULL, CHECK)

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Ejecutar y comprender métodos básicos de validación de datos
- B. Realizar verificaciones de tipo, rango y referencias cruzadas (cross-reference).
 - Estas verificaciones actúan como la primera línea de defensa para garantizar que los datos sean lógicamente coherentes antes de realizar cualquier análisis profundo.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Ejecutar y comprender métodos básicos de validación de datos
- B. Realizar verificaciones de tipo, rango y referencias cruzadas (cross-reference).
 - **1. Verificaciones de Tipo (Type Checks)**
 - Consiste en asegurar que cada columna tenga el tipo de dato correcto (entero, flotante, booleano, string o fecha) para evitar errores en las operaciones matemáticas o lógicas.
 - En Python: Se utiliza `.dtypes` para inspeccionar los tipos y `pd.to_numeric()` o `pd.to_datetime()` para forzar la conversión. El argumento `errors='coerce'` es clave para transformar los valores inválidos en NaN.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Ejecutar y comprender métodos básicos de validación de datos
- B. Realizar verificaciones de tipo, rango y referencias cruzadas (cross-reference).
 - **2. Verificaciones de Rango (Range Checks)**
 - Aseguran que los valores numéricos o de fechas se encuentren dentro de los límites lógicos, biológicos o de negocio permitidos (por ejemplo: edades entre 0 y 120, o calificaciones entre 0 y 10).
 - En Python: Se suele utilizar el método `.between()` o condiciones booleanas tradicionales (`>`, `<`) para filtrar o etiquetar registros fuera de rango.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Ejecutar y comprender métodos básicos de validación de datos
- B. Realizar verificaciones de tipo, rango y referencias cruzadas (cross-reference).
 - **3. Verificaciones de Referencias Cruzadas (Cross-Reference Checks)**
 - Estas verificaciones evalúan las relaciones lógicas entre diferentes columnas del mismo dataset (lógica interna) o la relación entre tablas distintas (integridad referencial).
 - Ejemplo interno: La "Fecha de entrega" no puede ser anterior a la "Fecha de compra".
 - Ejemplo externo: Que un ID_Cliente en la tabla de ventas realmente exista en la tabla maestra de clientes.
 - En Python: Se aplican comparaciones directas entre columnas o la función `.isin()` para validar la existencia de claves entre diferentes DataFrames.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Ejecutar y comprender métodos básicos de validación de datos
- C. Explicar el beneficio de las verificaciones de tipo tempranas en los scripts de ingesta de datos.
 - **Validación de datos.** Beneficio de las validaciones tempranas
 - Detecta errores antes de procesar datos
 - Evita propagación de datos incorrectos
 - Reduce coste de limpieza posterior
 - Mejora la calidad del pipeline de datos
 - Evita errores en modelos de machine learning

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Establecer y mantener la integridad de los datos mediante reglas de validación claras.
- A. Comprender el concepto de integridad de datos y su importancia para mantener bases de datos fiables y precisas.
- **Integridad de los datos:** Se refiere a la exactitud, consistencia y confiabilidad de los datos a lo largo de todo su ciclo de vida. Implica asegurar que no se alteren de forma no autorizada, que no existan duplicaciones o pérdidas, y que las relaciones entre datos se mantengan coherentes. Esto garantiza que la información refleje fielmente la realidad y sea confiable para la toma de decisiones.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESING

- Establecer y mantener la integridad de los datos mediante reglas de validación claras.
- A. Comprender el concepto de integridad de datos y su importancia para mantener bases de datos fiables y precisas.
 - La integridad de datos es la garantía de que los datos son:
 - Correctos
 - Consistentes
 - Completos
 - Confiables a lo largo del tiempo
 - Importancia:
 - Evita errores en análisis
 - Mantiene coherencia entre sistemas
 - Asegura confianza en decisiones basadas en datos
 - Es fundamental en bases de datos y sistemas críticos

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Establecer y mantener la integridad de los datos mediante reglas de validación claras.
- B. Aplicar reglas de validación claras que garanticen la corrección y la consistencia de los datos.
 - Las reglas de validación ayudan a mantener la calidad del dato.
 - Ejemplos de reglas:
 - Un campo obligatorio no puede estar vacío (NOT NULL)
 - Edad ≥ 0
 - Emails deben tener formato válido
 - Fechas deben ser coherentes (inicio $\leq$ fin)
 - Claves únicas en bases de datos (PRIMARY KEY)
 - Aplicación práctica:
 - En bases de datos:
 - constraints (CHECK, UNIQUE)
 - En Python: validaciones en scripts de ingestión
 - En APIs: validación de esquemas (Pydantic, JSON Schema)

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

Data Preparation Techniques

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- **Importancia de preparar los datos para el análisis.**
 - Antes de analizar datos, es necesario limpiarlos y prepararlos.
 - Tareas comunes:
 - Eliminar duplicados
 - Corregir errores
 - Gestionar valores vacíos
 - Normalizar formatos
 - Ejemplo:
 - Fechas incorrectas:
 - 12/05/24
 - 2024-05-12
 - 05-12-2024
 - Solución:
 - Unificar formato.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender formatos de archivos en adquisición de datos
- A. Explicar funciones y características de formatos comunes
 - **CSV (Comma-Separated Values)**
 - Formato tabular (filas y columnas)
 - Muy usado en análisis de datos y Excel
 - Características:
 - Simple y ligero
 - Fácil de leer en Python y herramientas BI
 - No soporta estructuras complejas
 - Limitaciones:
 - No permite jerarquías
 - No guarda tipos de datos explícitos

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender formatos de archivos en adquisición de datos
- A. Explicar funciones y características de formatos comunes
 - **JSON (JavaScript Object Notation)**
 - Formato estructurado basado en pares clave-valor
 - Soporta estructuras anidadas
 - Características:
 - Muy usado en APIs y web
 - Flexible y legible
 - Compatible con objetos complejos
 - Limitaciones:
 - Más pesado que CSV
 - Menos eficiente para grandes volúmenes tabulares

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender formatos de archivos en adquisición de datos
- A. Explicar funciones y características de formatos comunes
 - **XML (eXtensible Markup Language)**
 - Formato jerárquico basado en etiquetas
 - Similar a HTML en estructura
 - Características:
 - Muy estructurado
 - Permite jerarquías complejas
 - Usado en sistemas *legacy* y configuración
 - Limitaciones:
 - Verboso (mucho texto repetido)
 - Más difícil de leer y procesar

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender formatos de archivos en adquisición de datos
- A. Explicar funciones y características de formatos comunes
 - **TXT (Plain Text)**
 - Archivo de texto sin estructura definida
 - Características:
 - Muy flexible
 - Usado para logs, notas o texto libre
 - Limitaciones:
 - No tiene estructura de datos
 - Requiere procesamiento adicional para análisis

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Comprender formatos de archivos en adquisición de datos
- B. Comprender métodos básicos de importación y exportación
- En análisis de datos, es fundamental saber leer y guardar distintos tipos de archivos.

Formato	Importación Pandas	Importación Python	Exportación Pandas	Exportación Python
CSV	pd.read_csv()	csv.reader()	df.to_csv()	csv.writer()
JSON	pd.read_json()	json.load()	df.to_json()	json.dump()
XML	pd.read_xml()	xml.etree.ElementTree.parse()	df.to_xml()	xml.etree.ElementTree.write()
TXT	pd.read_csv() (o read_table())	open() / read()	df.to_csv() (o to_string())	open() / write()

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Acceder, gestionar y utilizar datasets eficazmente
- A. Comprender acceso a datasets desde diferentes fuentes
 - Los datos son la base de cualquier análisis, modelo predictivo o sistema de inteligencia artificial.
 - Saber acceder a ellos, organizarlos y prepararlos correctamente es fundamental para obtener resultados fiables y útiles.
 - El trabajo con datasets implica tres etapas clave:
 - **Acceso a los datos:** localizar y obtener información desde distintas fuentes.
 - **Gestión de datos:** organizar y mantener los datos de forma estructurada.
 - **Utilización eficiente:** transformar y preparar los datos para su análisis.
 - Una mala gestión de datos puede provocar errores, sesgos y conclusiones incorrectas.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- **Acceder, gestionar y utilizar datasets eficazmente**
- A. Comprender acceso a datasets desde diferentes fuentes
 - **1. Local files (Archivos locales)**
 - Son archivos almacenados en el propio dispositivo o sistema.
 - Formatos comunes:
 - CSV (Comma Separated Values)
 - Excel (XLSX)
 - JSON
 - TXT
 - Ventajas:
 - Fácil acceso
 - Simples de manejar
 - Útiles para proyectos pequeños
 - Desventajas:
 - Actualización manual
 - Limitación de tamaño
 - Ejemplo de uso:
 - Ventas de una tienda almacenadas en un archivo Excel.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Acceder, gestionar y utilizar datasets eficazmente
- A. Comprender acceso a datasets desde diferentes fuentes
 - **2. Databases (Bases de datos)**
 - Sistemas estructurados para almacenar grandes volúmenes de información.
 - Tipos:
 - Relacionales (SQL)
 - No relacionales (NoSQL)
 - Ejemplos de uso:
 - Información de clientes, historial de compras, inventarios
 - Ventajas:
 - Gran capacidad
 - Consultas rápidas
 - Seguridad y escalabilidad
 - Herramientas comunes:
 - SQL
 - MySQL
 - PostgreSQL
 - MongoDB

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Acceder, gestionar y utilizar datasets eficazmente
- A. Comprender acceso a datasets desde diferentes fuentes
 - **3. Online repositories (Repositorios online)**
 - Plataformas que ofrecen datasets públicos o compartidos.
 - Ejemplos:
 - Kaggle
 - UCI Machine Learning Repository
 - Google Dataset Search
 - Ventajas:
 - Acceso a datos reales
 - Amplia variedad de temas
 - Útiles para aprendizaje y experimentación
 - Desventajas:
 - Calidad variable
 - Necesidad de validación

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Acceder, gestionar y utilizar datasets eficazmente
- B. Comprender principios de gestión de datos
 - La gestión de datos consiste en mantener la información organizada y preparada para su análisis. Los principios fundamentales son:
 - **1. Organizing data** (Organización de datos) → Consiste en estructurar la información de forma lógica y clara.
 - Buenas prácticas:
 - Nombrar columnas correctamente
 - Mantener formatos consistentes
 - Separar variables por categorías
 - Ejemplo:
 - Incorrecto: NombreEdadCiudad
 - Correcto: Nombre | Edad | Ciudad
 - Beneficios:
 - Facilita la lectura
 - Reduce errores
 - Mejora el análisis

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Acceder, gestionar y utilizar datasets eficazmente
- B. Comprender principios de gestión de datos
 - **2. Sorting data** (Ordenación de datos) → Permite organizar los datos según criterios específicos.
 - Tipos de ordenación:
 - Ascendente
 - Descendente
 - Alfabética
 - Cronológica
 - Ejemplo:
 - Ordenar ventas de mayor a menor para identificar productos más vendidos.
 - Ventajas:
 - Detectar patrones
 - Encontrar valores extremos
 - Facilitar comparaciones

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Acceder, gestionar y utilizar datasets eficazmente
- B. Comprender principios de gestión de datos
 - **3. Filtering data** (Filtrado de datos) → Seleccionar solo la información relevante para el análisis.
 - Ejemplos:
 - Clientes mayores de 18 años
 - Ventas del último mes
 - Productos con stock bajo
 - Beneficios:
 - Reduce volumen de datos
 - Mejora enfoque analítico
 - Ahorra tiempo

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- **Extraer datos desde diversas fuentes**
- A. Explicar técnicas fundamentales de extracción de datos
 - La extracción de datos es el proceso de obtener información desde diferentes sistemas o plataformas para su posterior análisis.
 - Es una fase fundamental en ciencia de datos, automatización y análisis de información.
 - Las fuentes más comunes son:
 - Bases de datos
 - APIs
 - Servicios online
 - Páginas web
 - Ficheros
 - El objetivo es recopilar datos de forma eficiente, estructurada y fiable.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- **Extraer datos desde diversas fuentes**
- A. Explicar técnicas fundamentales de extracción de datos
 - **1. Extracting from databases (Bases de datos)**
 - Las bases de datos almacenan información estructurada.
 - La extracción se realiza mediante consultas.
 - Lenguaje principal:SQL (Structured Query Language)
 - Ejemplo:
 - `SELECT name, ageFROM customersWHERE age > 18;`
 - Ventajas:
 - Acceso rápido
 - Datos organizados
 - Consultas precisas
 - Casos de uso:
 - Clientes
 - Ventas
 - Inventarios

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- **Extraer datos desde diversas fuentes**
- **B. Explicar técnicas fundamentales de extracción de datos**
 - **2. Extracting from APIs**
 - Una API (Application Programming Interface) permite que aplicaciones intercambien datos automáticamente.
 - Muchas plataformas ofrecen APIs para acceder a información.
 - Ejemplos:
 - X API
 - OpenWeather API
 - Google Maps API
 - Métodos comunes:
 - GET → obtener datos
 - POST → enviar datos
 - Formato habitual:
 - JSON
 - Ventajas:
 - Datos actualizados
 - Automatización
 - Integración sencilla

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- **Extraer datos desde diversas fuentes**
- A. Explicar técnicas fundamentales de extracción de datos
 - **3. Extracting from online services**
 - Muchos servicios permiten exportar o conectar datos.
 - Ejemplos:
 - Formularios online
 - Plataformas cloud
 - Herramientas de análisis
 - Métodos:
 - Descarga manual
 - Integraciones automáticas
 - Conectores de datos
 - Beneficios:
 - Acceso rápido
 - Datos centralizados

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Extraer datos desde diversas fuentes
- B. Extraer datos HTML usando Python
 - Cuando una web no ofrece API, es posible extraer información directamente del HTML.
 - Esto se conoce como **web scraping**.
 - Herramientas principales (Python):
 - Módulo requests → Permite descargar el contenido de una página web.
 - Librería BeautifulSoup → Permite analizar y extraer elementos específicos del HTML.
 - Selenium → Automatización de navegación usando navegadores
 - Scrapy → Para web scraping a gran escala. Alto rendimiento.
 - Usando pandas → read_html → Solo tablas.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Extraer datos desde diversas fuentes
- C. Comprender desafíos en extracción de datos
 - 1. **Data compatibility** (Compatibilidad de datos)
 - Los datos pueden venir en distintos formatos:
 - CSV
 - JSON
 - XML
 - HTML
 - Problema:
 - Integrarlos puede ser complejo.
 - Solución:
 - Estandarizar formatos.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- **Extraer datos desde diversas fuentes**
- C. Comprender desafíos en extracción de datos
 - **2. Data integrity (Integridad de datos)**
 - Es importante que los datos sean correctos y completos.
 - Problemas comunes:
 - Datos incompletos
 - Duplicados
 - Errores de formato
 - Ejemplo:
 - Edad = “twenty-five” en lugar de 25
 - Solución:
 - Validación y limpieza.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- **Extraer datos desde diversas fuentes**
- **C. Comprender desafíos en extracción de datos**
 - **3. Changing structures (Cambios en estructura)**
 - Las páginas web pueden cambiar su HTML.
 - Consecuencia:
 - El scraper puede dejar de funcionar.
 - Solución:
 - Mantenimiento continuo.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- **Extraer datos desde diversas fuentes**
- **C. Comprender desafíos en extracción de datos**
 - **4. Access restrictions (Restricciones de acceso)**
 - Algunas webs bloquean scraping.
 - Métodos de protección:
 - CAPTCHA
 - Login
 - IP blocking

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- **Extraer datos desde diversas fuentes**
- D. Discutir prácticas éticas de web scraping
 - **1. Respect robots.txt**
 - El archivo robots.txt indica qué partes de una web pueden rastrearse.
 - Ejemplo:website.com/robots.txt
 - Su función:Definir reglas de acceso
 - Debe respetarse para evitar usos indebidos.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Extraer datos desde diversas fuentes
- D. Discutir prácticas éticas de web scraping
 - **2. Rate limiting (Limitar velocidad de peticiones)**
 - Enviar demasiadas solicitudes puede afectar al servidor.
 - Mala práctica → 1000 requests por minute
 - Buena práctica → Esperar entre solicitudes (uso de *time.sleep* en Python).
 - Beneficios:
 - Reduce carga
 - Evita bloqueos

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- **Extraer datos desde diversas fuentes**
- D. Discutir prácticas éticas de web scraping
 - **3. Respect terms of service**
 - Cada web tiene condiciones de uso.
 - Es importante revisar:
 - Permisos
 - Restricciones legales
 - **4. Avoid personal data misuse**
 - No recopilar ni utilizar datos personales sin autorización.
 - Importancia:
 - Privacidad
 - Protección legal
 - Seguridad

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- **Aplicar buenas prácticas de hojas de cálculo para legibilidad y formato**
- **A. Mejorar legibilidad y usabilidad de datos en spreadsheets**
 - Las hojas de cálculo son herramientas fundamentales para organizar, analizar y visualizar datos.
 - Sin embargo, una hoja mal estructurada puede dificultar la comprensión y aumentar errores.
 - Aplicar buenas prácticas mejora:
 - La legibilidad
 - La eficiencia
 - La precisión
 - La colaboración
 - Herramientas comunes:
 - Microsoft Excel
 - Google Sheets
 - LibreOffice Calc

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Aplicar buenas prácticas de hojas de cálculo para legibilidad y formato
- A. Mejorar legibilidad y usabilidad de datos en spreadsheets
 - **1. Layout adjustments (Ajustes de diseño)**
 - Una estructura clara facilita el trabajo con datos.
 - Buenas prácticas:
 - Use clear headers (Usar encabezados claros)
 - Cada columna debe tener un nombre descriptivo.
 - **2. Formatting best practices (Buenas prácticas de formato)**
 - El formato ayuda a destacar información importante.
 - Uso correcto de negritas; usar colores con criterio; utilizar bordes y espacios para la separación visual de la información; formateo correcto de números

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Aplicar buenas prácticas de hojas de cálculo para legibilidad y formato
- A. Mejorar legibilidad y usabilidad de datos en spreadsheets
 - **3. Basic formula applications (Aplicación de fórmulas básicas)**
 - Las fórmulas automatizan cálculos y reducen errores.
 - **4. Avoid common mistakes (Evitar errores comunes)**
 - Celdas vacías importantes
 - Datos duplicados
 - Formatos inconsistentes
 - Fórmulas incorrectas
 - Mezclar tipos de datos

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Aplicar buenas prácticas de hojas de cálculo para legibilidad y formato
- A. Mejorar legibilidad y usabilidad de datos en spreadsheets
 - **Benefits of spreadsheet best practices**(Beneficios de aplicar buenas prácticas):
 - Mayor claridad visual
 - Menos errores
 - Mejor análisis de datos
 - Trabajo más rápido
 - Mejor colaboración en equipo

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- A. Comprender contexto, objetivos y expectativas
 - Antes de analizar datos, es necesario prepararlos correctamente.
 - El preprocesamiento transforma datos “brutos” en datos útiles y fiables para el análisis.
 - Objetivos principales:
 - Mejorar calidad de datos
 - Reducir errores
 - Facilitar análisis
 - Optimizar modelos predictivos
 - El principio es simple: **Mejores datos → mejores resultados**

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- A. Comprender contexto, objetivos y expectativas
 - **1. Context (Contexto)** → Los datos tienen significado dentro de un entorno específico.
 - Ejemplo: Ventas de una tienda:
 - ¿Periodo analizado?
 - ¿Ubicación?
 - ¿Tipo de cliente?
 - Sin contexto, los datos pueden interpretarse mal.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- A. Comprender contexto, objetivos y expectativas
 - **2. Objectives (Objetivos)**
 - Definir qué queremos conseguir.
 - Ejemplos:
 - Predecir ventas
 - Analizar comportamiento de clientes
 - Detectar fraude
 - El objetivo determina cómo preparar los datos.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- A. Comprender contexto, objetivos y expectativas
 - 3. Stakeholder expectations (Expectativas de stakeholders)
 - Los stakeholders son las personas interesadas en el análisis.
 - Ejemplos:
 - Directivos
 - Clientes
 - Equipos técnicos
 - Preguntas clave:
 - ¿Qué información necesitan?
 - ¿Qué decisiones tomarán?
 - Esto ayuda a enfocar el análisis.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- B. Comprender conceptos básicos de preprocesamiento
 - **1. Sorting (Ordenación)**
 - Organizar datos por criterios.
 - Ejemplo:
 - Ordenar ventas de mayor a menor.
 - Beneficios:
 - Detectar patrones
 - Encontrar máximos y mínimos

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- B. Comprender conceptos básicos de preprocesamiento
 - **2. Filtering (Filtrado)**
 - Seleccionar información relevante.
 - Ejemplo:
 - Filtrar clientes mayores de 18 años.
 - Beneficios:
 - Reduce ruido
 - Mejora precisión

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- B. Comprender conceptos básicos de preprocesamiento
 - 3. Cleaning (Limpieza)
 - Eliminar problemas en los datos.
 - Ejemplos:
 - Valores vacíos
 - Duplicados
 - Errores tipográficos
 - Ejemplo:
 - Incorrecto:
 - madrid; MADRID
 - Correcto:
 - Madrid

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- C. Comprender importancia del formato correcto de datos
 - 1. Date-time consistency (Consistencia en fechas y horas)
 - Problema:
 - 12/05/2026
 - 2026-05-12
 - 05-12-26
 - Múltiples formatos generan errores.
 - Solución:
 - Usar un único formato.
 - Ejemplo recomendado: YYYY-MM-DD

CHAPTER 1 – DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- C. Comprender importancia del formato correcto de datos
 - **2. Consistent categories (Categorías consistentes)**
 - Problema:
 - Male
 - male
 - M
 - Solución → Estandarizar.
 - Correcto → Male

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- C. Comprender importancia del formato correcto de datos
 - **3. Data type alignment (Alineación de tipos de datos)**
 - Cada columna debe tener un tipo correcto:
 - Texto
 - Número
 - Fecha
 - Booleano
 - Ejemplo:
 - Edad = 25 → Correcto
 - Edad = twenty-five → Incorrecto

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- D. Introducir conceptos de estructuración de datasets
 - La estructura afecta directamente al análisis.
 - 1. Wide format (Formato ancho)
 - Cada variable tiene su propia columna.
 - Ejemplo:

Name	Jan	Feb	Mar
Ana	100	120	150
 - Ventajas:
 - Fácil lectura
 - Desventajas:
 - Menos flexible

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- D. Introducir conceptos de estructuración de datasets

- **2. Long format (Formato largo)**

- Los valores se distribuyen en filas.

- Ejemplo:

Name	Month	Sales
Ana	Jan	100
Ana	Feb	120

- Ventajas:

- Mejor para análisis y visualización
- Compatible con muchas herramientas

- Desventajas:

- Menos intuitivo visualmente

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- D. Introducir conceptos de estructuración de datasets
 - **¿Cuándo usar cada uno?**

- Wide → reportes

Name	Jan	Feb	Mar
Ana	100	120	150

- Long → análisis estadístico

Name	Month	Sales
Ana	Jan	100
Ana	Feb	120

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- **E. Explicar división de datos en entrenamiento y prueba**
 - En proyectos de machine learning, los datos deben dividirse.
 - Objetivo:
 - Evaluar si el modelo funciona bien con datos nuevos.
 - Training set (Conjunto de entrenamiento)
 - Se usa para enseñar al modelo. Normalmente: 70–80%
 - Testing set (Conjunto de prueba)
 - Se usa para evaluar el modelo. Normalmente: 20–30%

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- **E. Explicar división de datos en entrenamiento y prueba**
 - Beneficio:
 - Evitar **overfitting**.
 - **Overfitting**
 - Definición:
 - Cuando el modelo memoriza datos en lugar de aprender patrones.
 - Consecuencia:
 - Mal rendimiento en nuevos datos.

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- **F. Comprender impacto del manejo de outliers**
 - Los outliers son valores anormalmente altos o bajos.
 - Distorsionar medias
 - Alterar modelos
 - Generar conclusiones incorrectas
 - Detecting outliers (Detectar outliers)
 - Visualización (boxplots)
 - Rango intercuartílico (IQR)
 - Z-score

CHAPTER 1 — DATA ACQUISITION AND PRE-PROCESSING

- Preparar, adaptar y preprocesar datos para análisis
- **F. Comprender impacto del manejo de outliers**
 - Managing outliers (Gestionar outliers) → La decisión depende del contexto.
 - Eliminar
 - Corregir
 - Transformar
 - Mantener (si son válidos)