



PYTHON

PCAD – CERTIFIED ASSOCIATE DATA ANALYST WITH PYTHON
CHAPTER 3 – STATISTICAL ANALYSIS

CHAPTER 3 — STATISTICAL ANALYSIS

Descriptive Statistics

CHAPTER 3 — STATISTICAL ANALYSIS

- Comprender y aplicar medidas estadísticas en el análisis de datos
- A. Medidas de tendencia central y dispersión
 - **Medidas de tendencia central.** Describen el valor representativo o “centro” de un conjunto de datos.
 - Media (Mean) → Promedio aritmético de los datos.
 - Mediana (Median) → Valor central cuando los datos están ordenados.
 - Moda (Mode) → Valor que aparece con mayor frecuencia.

CHAPTER 3 — STATISTICAL ANALYSIS

- **Comprender y aplicar medidas estadísticas en el análisis de datos**
- A. Medidas de tendencia central y dispersión
 - **Medidas de dispersión.** Indican cuánto varían los datos respecto al centro.
 - Rango (Range) → Diferencia entre el valor máximo y mínimo.
 - Varianza (Variance) → Mide la dispersión promedio respecto a la media.
 - Desviación estándar (Standard Deviation) → Raíz cuadrada de la varianza; expresa dispersión en las mismas unidades de los datos.
 - Poblacional → Se dispone de todos los datos (100%) de la población.
 - Muestral → Se dispone de una muestra de la población.
 - Rango intercuartílico (IQR) → El rango intercuartílico (Interquartile Range) es una medida estadística que nos dice cuánto de dispersos están el 50% de los datos centrales de un grupo. Ignora los extremos y, por lo tanto, los outliers
 - **Interpretación**
 - Baja dispersión → datos más homogéneos.
 - Alta dispersión → mayor variabilidad e incertidumbre.


CHAPTER 3 — STATISTICAL ANALYSIS

- Comprender y aplicar medidas estadísticas en el análisis de datos
- A. Medidas de tendencia central y dispersión

Medida Estadística	Python Nativo (statistics / básico)	NumPy	Pandas
Media	statistics.mean(datos)	np.mean(datos)	df.mean()
Mediana	statistics.median(datos)	np.median(datos)	df.median()
Moda	statistics.mode(datos)	No tiene función directa integrada	df.mode()
Rango	max(datos) - min(datos)	np.ptp(datos)	df.max() - df.min()
Varianza	statistics.variance(datos) (muestral)	np.var(datos) (poblacional por defecto)	df.var() (muestral por defecto)
	statistics.pvariance(datos) (poblacional)	np.var(datos, ddof=1) (muestral)	df.var(ddof=0) (poblacional)
Desviación Estándar	statistics.stdev(datos) (muestral)	np.std(datos) (poblacional por defecto)	df.std() (muestral por defecto)
	statistics.pstdev(datos) (poblacional)	np.std(datos, ddof=1) (muestral)	df.std(ddof=0) (poblacional)
Rango Intercuartílico (IQR)	statistics.quantiles(datos, n=4) q1 = cuartiles[0] q3 = cuartiles[2]	np.percentile(datos, 75) - np.percentile(datos, 25)	df.quantile(0.75) - df.quantile(0.25)


CHAPTER 3 — STATISTICAL ANALYSIS

- Comprender y aplicar medidas estadísticas en el análisis de datos
- B. Distribuciones estadísticas fundamentales e interpretación
 - **Distribución Gaussiana (Normal)**
 - Características:
 - Forma de campana simétrica.
 - La media, mediana y moda coinciden.
 - Muchas variables naturales siguen esta distribución:
 - Altura
 - Peso
 - Errores de medición
 - Interpretación:
 - Valores cercanos a la media son más frecuentes.
 - Valores extremos son menos probables.



CHAPTER 3 — STATISTICAL ANALYSIS

- Comprender y aplicar medidas estadísticas en el análisis de datos
- B. Distribuciones estadísticas fundamentales e interpretación
 - **Distribución Uniforme**
 - Características:
 - Todos los valores tienen la misma probabilidad.
 - Distribución plana.
 - Ejemplos:
 - Lanzamiento ideal de un dado.
 - Números aleatorios.



CHAPTER 3 — STATISTICAL ANALYSIS

- **Comprender y aplicar medidas estadísticas en el análisis de datos**
- **B. Distribuciones estadísticas fundamentales e interpretación**
 - **Interpretación de tendencias en diferentes contextos.**
 - **A. Contexto Univariante (Una sola variable).** Analiza cómo se comporta una única característica de forma aislada.
 - Tendencia Gaussiana: Se busca simetría. A partir de la media y la varianza, se puede predecir con mucha precisión si un dato es "común" o "atípico" (outlier).
 - Tendencia Uniforme: Se busca homogeneidad. Si dividimos los datos en rangos (por ejemplo, mediante un histograma), cada barra debería tener aproximadamente la misma altura. No hay valores atípicos, solo límites máximos y mínimos.
 - **B. Contexto Bivariante (Dos variables).** Se analiza cómo interactúan las distribuciones dos variables y si existe correlación.
 - Tendencia Gaussiana (Bivariante): Visualizada en un gráfico de dispersión (scatterplot), forma una especie de elipse o nube ovalada. Permite analizar la correlación.
 - Tendencia Uniforme (Bivariante): En un gráfico de dispersión, los puntos se distribuyen de manera homogénea formando un cuadrado o un rectángulo perfecto. Esto es un indicador inequívoco de que las dos variables son completamente independientes y no tienen relación entre sí.

CHAPTER 3 — STATISTICAL ANALYSIS

- Comprender y aplicar medidas estadísticas en el análisis de datos
- B. Distribuciones estadísticas fundamentales e interpretación
 - Interpretación de tendencias en diferentes contextos.
 - C. Contexto Multivariante (Tres o más variables). En problemas complejos (como el aprendizaje automático o Machine Learning), las distribuciones se extienden a hiperespacios de muchas dimensiones.
 - Tendencia Gaussiana (Multivariante): **ocurre cuando los datos tienen un centro de gravedad. Las variables trabajan están conectadas.** En un gráfico, los datos formarían una nube con forma de balón de fútbol americano o elipse. El centro de ese balón es el promedio del sistema, donde se acumula la gran mayoría de los datos.
 - Tendencia Uniforme (Multivariante): **ocurre cuando no existe ningún centro de atracción** ni favoritismo en los datos. **Las variables son totalmente independientes;** lo que le pasa a una no le importa a la otra. En un gráfico, los datos llenarían el espacio disponible de forma completamente homogénea.

CHAPTER 3 — STATISTICAL ANALYSIS

- **Comprender y aplicar medidas estadísticas en el análisis de datos**
- **B. Distribuciones estadísticas fundamentales e interpretación**
 - **Interpretación de tendencias en diferentes contextos.**
 - **D. Contexto A lo Largo del Tiempo (Series Temporales).** Cuando se introduce el factor tiempo, se evalúa si la naturaleza de la distribución se mantiene o cambia (estacionariedad).
 - **Tendencia Gaussiana en el tiempo:** describe un sistema que tiene memoria y busca la estabilidad. Las fluctuaciones de las variables a lo largo del tiempo se comportan como si estuvieran atadas a un elástico. Las variables se mueven juntas y tienden a regresar constantemente a un camino central o promedio histórico.
 - **Tendencia Uniforme en el tiempo:** describe un sistema sin memoria, donde el pasado no influye en el futuro A lo largo del tiempo, los valores de las variables cambian de forma completamente aleatoria.

CHAPTER 3 — STATISTICAL ANALYSIS

- Comprender y aplicar medidas estadísticas en el análisis de datos
- C. Medidas de confianza y fiabilidad de datos
 - **Intervalos de confianza**
 - Un intervalo de confianza del 95% para la media de una población significa que, si repitiéramos el muestreo muchas veces y construyéramos un intervalo de confianza en cada muestra del mismo modo, aproximadamente el 95% de esos intervalos contendrían el verdadero valor de la media poblacional.
 - El intervalo está compuesto por dos valores simétricos respecto a la media marcan un área:
 - El % incluido → **nivel de confianza**. Probabilidad de quedar dentro del área. Los más utilizados son 95% y 99%.
 - El % excluido → **nivel de significación**. Probabilidad de quedar fuera del área (50% por abajo; 50% por encima).
 - **El intervalo de confianza** → rango de valores entre los que está el nivel de confianza buscado.
 - Intervalos estrechos → mayor precisión.
 - Intervalos amplios → mayor incertidumbre.
 - El tamaño de muestra influye directamente en la confiabilidad.

CHAPTER 3 — STATISTICAL ANALYSIS

■ Comprender y aplicar medidas estadísticas en el análisis de datos

```
import numpy as np
import scipy.stats as st
```

```
# Simulamos una muestra grande (1000 usuarios)
np.random.seed(42) # Para que siempre dé el mismo resultado
datos_grandes = np.random.normal(loc=5, scale=1.5, size=1000)
```

```
media = np.mean(datos_grandes)
error_estandar = st.sem(datos_grandes)
nivel_confianza = 0.95
```



Media de la muestra grande: 5.03
Intervalo de confianza del 95%
(Z):
(np.float64(4.937961107627906),
np.float64(5.12003505983907))

```
# Calculamos usando la distribución Normal (no requiere
# grados de libertad)
intervalo_z = st.norm.interval(confidence=nivel_confianza,
                               loc=media,
                               scale=error_estandar)
```

```
print(f"Media de la muestra grande: {media:.2f}")
print(f"Intervalo de confianza del 95% (Z): {intervalo_z}")
```

CHAPTER 3 — STATISTICAL ANALYSIS

■ Comprender y aplicar medidas estadísticas en el análisis de datos

```
import numpy as np
import scipy.stats as st
```

```
# 1. Creamos unos datos de ejemplo (por ejemplo, horas de uso del móvil)
datos = [4.5, 5.2, 6.0, 4.8, 5.1, 4.3, 5.5, 4.9, 5.2, 4.7]
```

```
# 2. Calculamos los datos básicos de la muestra
media = np.mean(datos)
error_estandar = st.sem(datos) # Error estándar de la media (SEM)
grados_libertad = len(datos) - 1
nivel_confianza = 0.95
```

```
# 3. Calculamos el intervalo de confianza
intervalo = st.t.interval(confidence=nivel_confianza,
                          df=grados_libertad,
                          loc=media,
                          scale=error_estandar)
```

```
print(f"Media de la muestra: {media:.2f}")
print(f"Intervalo de confianza del 95%: {intervalo}")
```



```
Media de la muestra: 5.02
Intervalo de confianza del 95%:
(np.float64(4.665034293601551),
 np.float64(5.3749657063984495))
```

CHAPTER 3 — STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- A. **Identificación de outliers** y análisis de correlaciones
 - **Outliers (valores atípicos)**
 - Los outliers son observaciones que se alejan significativamente del resto de los datos.
 - Posibles causas:
 - Errores de medición.
 - Variabilidad natural.
 - Datos anómalos o eventos excepcionales.

CHAPTER 3 — STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- A. **Identificación de outliers** y análisis de correlaciones
 - **Outliers (valores atípicos)**
 - Impacto de los outliers:
 - Distorsionan medias y desviaciones estándar.
 - Pueden afectar modelos estadísticos y predictivos.
 - Influyen en el análisis de correlación.
 - Métodos comunes de detección:
 - Boxplots.
 - Rango intercuartílico (IQR).
 - Z-score.

CHAPTER 3 — STATISTICAL ANALYSIS

- **Analizar y evaluar relaciones entre datos**
- **A. Identificación de outliers y análisis de correlaciones**
 - **Correlación entre variables** → La correlación mide la relación entre dos variables.
 - **Coeficiente de correlación de Pearson (r)**
 - El coeficiente de Pearson mide cuánto se alinean dos variables en una línea recta.
 - Por ejemplo, si quieres saber si a más horas de estudio corresponden mejores calificaciones, este número te lo dice.
 - **Ventaja que tiene frente a la covarianza** → el efecto de la escala.
 - La covarianza depende de las unidades: el cálculo de la covarianza entre peso y altura cambia si se utilizan diferentes unidades (peso en kilos o en gramos) → dificultad para interpretar.
 - El coeficiente de Pearson no se ve influido por las unidades → siempre te va a dar un resultado entre -1 y 1.


CHAPTER 3 — STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- A. Identificación de outliers y **análisis de correlaciones**
 - Correlación entre variables → La correlación mide la relación entre dos variables.
 - **Coeficiente de correlación de Pearson (r)**
 - Interpretación de Pearson's R

Valor de r	Interpretación
+1	Correlación positiva perfecta
0	Sin correlación lineal
-1	Correlación negativa perfecta

CHAPTER 3 – STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- A. Identificación de outliers y **análisis de correlaciones**
 - Correlación entre variables → La correlación mide la relación entre dos variables.



CHAPTER 3 — STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- Coeficiente de correlación de Pearson (r) en Python+pandas → función **corr**.
- Ejemplo dos series:

```
import pandas as pd

# Creamos un ejemplo rápido
data = {
    'Horas_Estudio': [2, 5, 7, 10, 12],
    'Calificacion': [50, 65, 78, 90, 95]
}
df = pd.DataFrame(data)

# Calculamos la correlación de Pearson
correlacion = df['Horas_Estudio'].corr(df['Calificacion'])

print(f"El coeficiente de Pearson es: {correlacion}")
# Resultado: 0.994 (Una relación positiva casi perfecta)
```

CHAPTER 3 — STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- Coeficiente de correlación de Pearson (r) en Python+pandas → función **corr**.
- Ejemplo dataframe:

```
import pandas as pd

data = {
    'Horas_Estudio': [2, 5, 7, 10, 12],
    'Calificación': [50, 65, 78, 90, 95],
    'Asistencias': [10, 18, 20, 22, 25],
    'Nombre_Alumno': ['Ana', 'Luis', 'Pedro', 'Sofía', 'Carlos']
}
df = pd.DataFrame(data)

# Genera una tabla con todas las combinaciones posibles solo para
# datos numéricos
matriz_correlacion =
df.select_dtypes(include='number').corr(method='pearson') #
'pearson' es el valor por defecto

print(matriz_correlacion)
```

	Horas_Estudio	Calificación	Asistencias
Horas_Estudio	1.000000	0.991281	0.959210
Calificación	0.991281	1.000000	0.966892
Asistencias	0.959210	0.966892	1.000000




CHAPTER 3 — STATISTICAL ANALYSIS

- **Analizar y evaluar relaciones entre datos**
- A. Identificación de outliers y análisis de correlaciones
 - **Correlación entre variables → Coeficiente de correlación de Pearson (r)**
 - **Correlación positiva**
 - Ambas variables aumentan juntas.
 - Ejemplo: horas de estudio y calificación.
 - **Correlación negativa**
 - Una variable aumenta mientras la otra disminuye.
 - Ejemplo: velocidad y tiempo de viaje.
 - **Consideraciones importantes**
 - Correlación no implica causalidad.
 - Pearson mide relaciones lineales.
 - Los outliers pueden alterar significativamente el coeficiente.


CHAPTER 3 — STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- B. Interpretación y evaluación crítica de gráficos
 - **Boxplot**
 - Objetivo → Visualizar distribución, dispersión y outliers.
 - Elementos principales:
 - Mediana.
 - Cuartiles.
 - Rango intercuartílico.
 - Valores atípicos.
 - Utilidad
 - Comparar grupos.
 - Detectar asimetrías y anomalías.




CHAPTER 3 — STATISTICAL ANALYSIS

- **Analizar y evaluar relaciones entre datos**
- B. Interpretación y evaluación crítica de gráficos
 - **Histograma**
 - Objetivo → Representar la distribución de frecuencias.
 - Permite identificar:
 - Forma de la distribución.
 - Sesgo.
 - Concentración de datos.
 - Distribuciones normales o multimodales.
 - Interpretación
 - Barras altas → mayor frecuencia.
 - Distribución simétrica o asimétrica.




CHAPTER 3 — STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- B. Interpretación y evaluación crítica de gráficos
 - **Scatterplot** (diagrama de dispersión)
 - Objetivo → Mostrar relación entre dos variables.
 - Permite detectar:
 - Correlaciones positivas o negativas.
 - Tendencias.
 - Agrupamientos.
 - Outliers.
 - Interpretación
 - Patrón ascendente → correlación positiva.
 - Patrón descendente → correlación negativa.
 - Sin patrón → baja correlación.




CHAPTER 3 — STATISTICAL ANALYSIS

- **Analizar y evaluar relaciones entre datos**
- B. Interpretación y evaluación crítica de gráficos
 - **Lineplot** (gráfico de líneas)
 - Objetivo → Visualizar cambios a lo largo del tiempo.
 - Aplicaciones
 - Series temporales.
 - Evolución de métricas.
 - Tendencias y estacionalidad.
 - Interpretación
 - Pendientes ascendentes o descendentes
 - Cambios bruscos.
 - Ciclos repetitivos.



CHAPTER 3 — STATISTICAL ANALYSIS

- **Analizar y evaluar relaciones entre datos**
- B. Interpretación y evaluación crítica de gráficos
 - **Correlation Heatmap**
 - Objetivo → Visualizar correlaciones entre múltiples variables.
 - Características
 - Utiliza colores para representar intensidad y dirección de correlaciones.
 - Facilita detectar relaciones fuertes o redundancias.
 - Interpretación
 - Valores cercanos a +1 → correlación positiva fuerte.
 - Valores cercanos a -1 → correlación negativa fuerte.
 - Valores cercanos a 0 → relación débil.



CHAPTER 3 — STATISTICAL ANALYSIS

- **Analizar y evaluar relaciones entre datos**
- B. Interpretación y evaluación crítica de gráficos
 - Evaluación crítica de visualizaciones
 - Al interpretar gráficos se debe considerar:
 - Calidad y tamaño de la muestra.
 - Presencia de outliers.
 - Escalas utilizadas.
 - Posibles sesgos visuales.
 - Contexto de los datos.
 - Idea clave → el análisis de relaciones entre variables y la correcta interpretación de gráficos permiten descubrir patrones, detectar anomalías y obtener conclusiones fundamentadas a partir de los datos.

CHAPTER 3 — STATISTICAL ANALYSIS

Inferential Statistics

CHAPTER 3 — STATISTICAL ANALYSIS

- Bootstrapping para distribuciones muestrales
- A. Fundamentos teóricos y principios estadísticos del bootstrapping
 - Bootstrapping es una técnica de remuestreo que permite estimar la distribución muestral utilizando únicamente la muestra disponible.
 - Se basa en realizar múltiples muestras aleatorias con reemplazo a partir de los datos originales → **Se genera una nueva muestra**
 - **Cada nueva muestra tiene el mismo tamaño que la muestra original.**
 - Permite estimar:
 - Media
 - Varianza
 - Error estándar
 - Intervalos de confianza
 - Sesgo estadístico
 - Ventajas:
 - No requiere asumir normalidad.
 - Útil cuando el tamaño muestral es pequeño o la distribución es desconocida.

CHAPTER 3 — STATISTICAL ANALYSIS

- **Bootstrapping para distribuciones muestrales**
- B. Diferencias entre datos discretos y continuos en bootstrapping
 - **Datos discretos**
 - Valores contables o categóricos.
 - Ejemplos:
 - Número de errores
 - Respuestas Sí/No
 - Cantidad de clientes
 - En bootstrapping:
 - Se remuestran observaciones exactas.
 - Puede haber muchas repeticiones del mismo valor.

CHAPTER 3 — STATISTICAL ANALYSIS

- **Bootstrapping para distribuciones muestrales**
- B. Diferencias entre datos discretos y continuos en bootstrapping
 - **Datos continuos**
 - Valores medibles en escalas continuas.
 - Ejemplos:
 - Peso
 - Temperatura
 - Tiempo
 - En bootstrapping:
 - Se preserva la variabilidad de la distribución original.
 - Adecuado para estimar estadísticas complejas.

CHAPTER 3 — STATISTICAL ANALYSIS

- **Bootstrapping para distribuciones muestrales**
- **C. Situaciones donde el bootstrapping es efectivo**
 - Casos recomendados
 - Tamaños muestrales pequeños o moderados.
 - Distribuciones desconocidas o no normales.
 - Estadísticos difíciles de modelar analíticamente.
 - Problemas de inferencia en machine learning y ciencia de datos.
 - Aplicaciones comunes
 - Estimación de intervalos de confianza.
 - Validación de modelos predictivos.
 - Comparación de medias o medianas.
 - Limitaciones
 - Menos efectivo con muestras muy pequeñas y poco representativas.
 - Sensible a valores atípicos extremos.
 - Puede requerir alto costo computacional.

CHAPTER 3 — STATISTICAL ANALYSIS

- Bootstrapping para distribuciones muestrales
- D. Aplicación práctica de bootstrapping con Python
 - Flujo básico
 - Seleccionar una muestra original.
 - Generar múltiples remuestras con reemplazo.
 - Calcular un estadístico en cada remuestra.
 - Construir la distribución muestral estimada.
 - Analizar resultados e intervalos de confianza.

CHAPTER 3 — STATISTICAL ANALYSIS

- Bootstrapping para distribuciones muestrales
- D. Aplicación práctica de bootstrapping con Python
 - Ejemplo:

```
import numpy as np
```

```
# Datos originales
```

```
data = np.array([10, 12, 13, 15, 18, 20])
```

```
# Número de remuestras
```

```
n_boot = 1000
```

```
# Almacenar medias
```

```
boot_means = []
```

```
for _ in range(n_boot):
```

```
    sample = np.random.choice(data, size=len(data), replace=True)
```

```
    boot_means.append(np.mean(sample))
```

```
# Resultados
```

```
print("Media bootstrap:", np.mean(boot_means))
```

```
print("Error estándar:", np.std(boot_means))
```



Media bootstrap: 14.601666666666667

Error estándar: 1.3186261790211813

CHAPTER 3 — STATISTICAL ANALYSIS

- **Bootstrapping para distribuciones muestrales**
- E. Fiabilidad y validez de los resultados
 - Fiabilidad
 - Aumenta con un mayor número de remuestras.
 - Resultados más estables con muestras representativas.
 - Normalmente se utilizan entre 1,000 y 10,000 iteraciones.
 - Validez
 - Depende de que la muestra original represente bien a la población.
 - Bootstrapping no corrige sesgos de muestreo.
 - Debe evaluarse:
 - Presencia de outliers
 - Dependencia entre observaciones
 - Tamaño de muestra suficiente
 - Interpretación crítica
 - Comparar resultados bootstrap con métodos tradicionales.
 - Revisar amplitud de intervalos de confianza.
 - Analizar sensibilidad de los resultados ante cambios en los datos.

CHAPTER 3 — STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- A. Fundamentos teóricos y matemáticos de la regresión lineal
 - La regresión lineal modela la relación entre una variable dependiente continua y una o más variables independientes.
 - Objetivo:
 - Predecir valores y analizar relaciones lineales entre variables → Predicción
 - Aplicaciones comunes
 - Predicción de ventas.
 - Tendencias económicas.
 - Relación entre variables cuantitativas.

CHAPTER 3 — STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- B. Conceptos y fundamentos de la regresión logística
 - La regresión logística se utiliza cuando la variable dependiente es categórica, normalmente binaria.
 - Objetivo
 - Estimar probabilidades de ocurrencia de una clase → Clasificación
 - Características
 - Salida entre 0 y 1.
 - Clasificación binaria: Sí/No
 - Éxito/Fracaso
 - Casos de uso
 - Diagnóstico médico.
 - Detección de fraude.
 - Clasificación de clientes.

CHAPTER 3 — STATISTICAL ANALYSIS

- **Regresión lineal y logística: uso, aplicaciones y limitaciones**
- C. Elección entre regresión lineal y logística
 - Cuando usar regresión lineal:
 - Variable objetivo numérica.
 - Relación aproximadamente lineal.
 - Cuando usar regresión logística:
 - Variable objetivo binaria o categórica.
 - Interesa estimar probabilidades o clases.

Aspecto	Regresión lineal	Regresión logística
Tipo de salida	Continua	Categórica
Objetivo	Predicción numérica	Clasificación
Ejemplo	Precio de vivienda	Aceptado/Rechazado

CHAPTER 3 — STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- D. Datos discretos y continuos en regresión
 - Datos continuos
 - Valores medibles.
 - Utilizados típicamente en regresión lineal.
 - Ejemplos:
 - Temperatura
 - Ingresos
 - Altura
 - Datos discretos o categóricos
 - Valores contables o clases.
 - Utilizados en regresión logística.
 - Ejemplos:
 - Sí/No
 - 0/1
 - Aprobado/Reprobado

CHAPTER 3 — STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- E. Aplicación práctica con Python → **Regresión lineal**

```
from sklearn.linear_model import LinearRegression
import numpy as np
```

```
# Datos
X = np.array([[1], [2], [3], [4], [5]])
y = np.array([2, 4, 5, 4, 5])
```

```
# Modelo
model = LinearRegression()
model.fit(X, y)
```

```
# Predicción
prediction = model.predict([[6]])
```

```
print("Coeficiente:", model.coef_)
print("Intercepto:", model.intercept_)
print("Predicción:", prediction)
```

X son los datos de entrada
y los datos de salida (contínuos)

Coeficiente: [0.6]
Intercepto: 2.2
Predicción: [5.8]

CHAPTER 3 — STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- E. Aplicación práctica con Python → Regresión logística

```
from sklearn.linear_model import LogisticRegression
import numpy as np
```

```
# Datos
```

```
X = np.array([[1], [2], [3], [4], [5]])
```

```
y = np.array([0, 0, 0, 1, 1])
```

```
# Modelo
```

```
model = LogisticRegression()
```

```
model.fit(X, y)
```

```
# Probabilidad de clase
```

```
prob = model.predict_proba([[3.5]]) # Probabilidad: [[0.5208689 0.4791311]]
```

```
# prob = model.predict([[3.5]]) # Probabilidad: [0]
```

```
print("Probabilidad:", prob)
```

X son los datos de entrada
y los datos de salida (categóricos)

Probabilidad: [[0.5208689 0.4791311]]

Matriz de
probabilidades

Predicción

CHAPTER 3 — STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- F. Interpretación de resultados
 - **Regresión lineal**
 - Coeficientes
 - Indican cuánto cambia y por cada unidad de x .
 - Interpretación:
 - Cercano a 1 $\rightarrow$ buen ajuste.
 - Cercano a 0 $\rightarrow$ bajo poder explicativo.

CHAPTER 3 — STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- F. Interpretación de resultados
 - **Regresión logística**
 - Coeficientes
 - Representan cambios en log-odds (probabilidades logarítmicas).
 - Métricas comunes:
 - Accuracy.
 - Precision.
 - Recall.
 - ROC-AUC.
 - Interpretación
 - Probabilidades mayores a un umbral → clasificación positiva.

CHAPTER 3 — STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- G. Limitaciones, supuestos y sesgos
 - Limitaciones de la regresión lineal
 - Sensible a outliers.
 - No modela relaciones no lineales.
 - Problemas con multicolinealidad.
 - Limitaciones de la regresión logística
 - Requiere suficientes datos por clase.
 - Sensible a desbalance de clases.
 - Supone relación lineal en log-odds.

CHAPTER 3 — STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- G. Limitaciones, supuestos y sesgos
 - Posibles sesgos
 - Sesgo de selección.
 - Variables omitidas.
 - Datos no representativos.
 - Sobreajuste (overfitting).
 - Impacto en resultados
 - Predicciones poco fiables.
 - Interpretaciones incorrectas.
 - Generalización limitada.

CHAPTER 3 — STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- Idea clave:
 - La regresión lineal y logística son herramientas fundamentales para predicción y análisis estadístico; elegir el modelo adecuado depende del tipo de datos, la naturaleza del problema y el cumplimiento de los supuestos estadísticos.